AGENT FRAMEWORK · TRACEABLE RAG · COZE

让每个结论都有出处

用户端 Agent 框架、可溯源的混合检索知识库，以及管理端 Coze 智能体的工程实践。

答辩人 · 张城杰 · 2026.10.18

THE PROBLEM

模型给答案，系统给依据。

准确率只是入场券。医生敢不敢用，取决于能不能核对、能不能追责。

三个必须回答的问题

01 / HOW

这个恶性概率是怎么算出来的?

02 / WHY

凭什么相信它，依据在哪一条?

03 / WHAT NEXT

接下来该做什么，谁能替我做?

SYSTEM OVERVIEW · 01

三层结构，一条请求链路

用户端只关心答案；编排层决定怎么得到答案；证据层保证答案有据可查。

系统分三层：用户看到的交互层、做决策的编排层、提供证据的证据层。管理端是旁路，不进入用户请求链路。

L1 交互层
Flask 页面 + JSON API + SSE 流式

L2 编排层
Graph 状态机 + 13 个工具 + 权限/超时

L3 证据层
集成模型 + 校准 + 混合检索 + SQLite

L1 · 交互层

`Flask` `Jinja2` `SSE` `JSON API`

/predict · /result · /knowledge · /api/agent/llm/stream

L2 · 编排层

`Graph` `13 tools` `permissions` `checkpoint`

节点固定、边固定；checkpoint 支持回放与续跑。

L3 · 证据层

`ensemble` `calibration` `hybrid RAG` `SQLite`

30 维特征 → 集成模型 → 校准概率；1,035 条条款 → 混合检索。

TECH STACK · 02

没有黑盒框架，全部自建

答辩时能讲清每一层的实现，而不是"调了个库"。

01 / BACKEND

Python 3.11 · Flask

17,350 行 Python，173 个文件；gunicorn 1 worker × 4 threads。

02 / TEMPLATE

Jinja2 · HTML · CSS

21 个模板、13,612 行；结果页与知识库均为服务端渲染 + 渐进增强。

03 / FRONTEND

原生 JavaScript · SSE

不引入前端框架；事件流驱动 thinking / tool_call / token。

04 / ML

scikit-learn 集成

Voting / Stacking + sigmoid 校准与温度缩放；30 维 WDBC 特征。

05 / DATA

SQLite

预测记录、会话、检查点、RAG 倒排与向量，全部单文件可迁移。

06 / OPS

Shell · Nginx · Actions

systemd 双服务、Nginx 反代、GitHub Actions 自动部署。

PREDICTION PIPELINE · 03

一次预测，六步落地

01
填写 30 项
细胞核形态特征

02
/predict
校验 + 单位检查

03
标准化
训练集均值方差

04
集成模型
Voting / Stacking

05
概率校准
sigmoid + 温度缩放

06
结果页
入库 + 归因 + 证据强度

569
WDBC 样本，良性 357 / 恶性 212

30
细胞核特征：半径、纹理、面积、凹点…

0.022 s
单次推理耗时（结果页实测）



结果页，先给证据

恶性概率、校准置信度、输入距离、Top 5 归因和相似病例同时出现；每个数字都能点开看来源。

CALIBRATED
99.61%
校准后置信度

DISTANCE
1.948
输入分布距离（上限 15）

LATENCY
0.022s
单次推理

AGENT, NOT CHATBOT

Agent 不是聊天框。

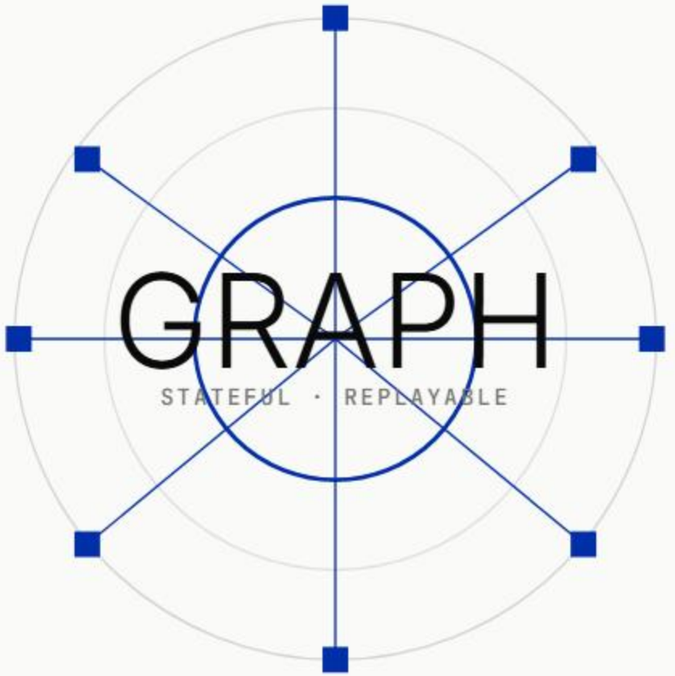
13
意图分类

11
图节点

13
注册工具

GRAPH · 11 NODES

01	guard	越界/敏感词拦截
02	cache	同问同答，跳过重复计算
03	route	13 类意图路由
04	act	调工具：模型/检索/记录/报告
05	assess	三档不确定性评估
06	compose	按意图合成答案
07	verify	数字对账 + 句子级 grounding
08	guard_out	免责声明与措辞兜底
09	persist	写会话、引用、检查点
10	finish	返回结果 / SSE done



DESIGN TRADEOFF · 04

为什么自研，而不是套框架

01 / ORCHESTRATION

编排层

Graph 负责顺序与分支，checkpoint 负责可恢复；节点固定、边固定，只有节点内部允许模型推理。

固定拓扑 · 可回放

02 / TOOLS

工具层

13 个注册工具，统一 schema、权限、超时与错误类型；模型只能通过工具碰数据。

最小权限 · 可审计

03 / GUARDRAILS

约束层

三档不确定性、引用门槛、免责声明；证据不足时明确说"不下结论"。

宁可少说 · 不可编造

TOOL REGISTRY · 05

模型只能通过工具碰数据

PREDICT

跑模型

30 维输入 → 恶性概率 + 校准置信度。

EXPLAIN

特征归因

近似 SHAP，给出方向与贡献，不声称因果。

SEARCH_KNOWLEDGE

检索条款

混合召回 + 重排，返回 clause_id 作为引用。

RECORDS / STATISTICS

查自己的数据

历史记录、趋势、活跃度，只读当前用户。

EXPORT_REPORT

交付产物

PDF 报告：结论、Top 8 归因、证据与免责声明。

DELEGATE

子代理

只读分析员，禁止递归；把长任务拆出去。

另含 get_clause / similar_cases / compare_records / sql_query / export_data / sessions 共 13 个工具；全部经 registry 注册并受权限约束。

TWO ENGINES · 06

同一套图，两种交付方式

SYNC · /API/AGENT/RUN-SYNC

一次返回
适合评测

输入问题，等图跑完，拿完整 JSON：intent、answer、citations、verify、trace。评测脚本和自动化都用它。

稳定 · 可断言

STREAM · /API/AGENT/LLM/STREAM

边想边给
过程可见

SSE 推送 start / thinking / tool_call / tool_result / sub_steps / token / done；前端逐步渲染，失败自动重试两次。

可观察 · 可中断

UNCERTAINTY · 07

不知道的时候，敢说不知道

CONFIDENT

置信

校准置信度 ≥ 0.79 且输入距离在范围内，正常给结论。

0.79

CLARIFY

谨慎

0.41–0.79 之间：给倾向，但明确标注不确定，建议补充信息。

0.41

ABSTAIN

弃权

低于 0.41 或距离 > 15：直接说"这组数据超出可靠范围"。

15.0

三档不是拍脑袋：阈值来自校准曲线与训练分布距离，评测里对应用例可复现。

GROUNDING · 07

每句话，都要能对上事实

引用不是脚注，是逐句核对后的结果。

01 句子切分
把答案拆成可独立核对的句子，中文按标点，英文按句号。

02 数字对账
答案里的每个数字都要在事实池里找到，容差 0.02 + 0.2%。

03 断言绑定
每句话映射到 clause_id 或 prediction/shap 事实，无出处标"推断"。

04 无据丢弃
编造的数字整句删掉，并在 verify 里记录 dropped。

OUTPUT

```
{ ok, coverage,
  claims: [...],
  dropped: n,
  unsupported: [...] }
```

覆盖率和丢弃数会随答案返回，前端可以展示"这句话没有依据"。

主要归因（数值来自模型归因结果，不是推测）：

1. `concave points_mean` = 0.0139 —— 推向良性
2. `concave_worst` = 0.0691 —— 推向良性
3. `area_worst` = 546.3 —— 推向良性
4. `perimeter_worst` = 85.22 —— 推向良性
5. `concavity_mean` = 0.0267 —— 推向良性

指标含义（引用特征词典）：

- 凹点平均值（concave points_mean）：轮廓凹陷点的数量。在数据集中，良性组均值约 0.0257，恶性组均值约 0.088；良性组 5%~95% 区间 0.0032 ~ 0.0564，恶性组 0.0339 ~ 0.1511。数值越高通常越提示细胞异型性明显（统计关联，非诊断阈值）。区间为该组 5%~95% 分位范围，属统计描述，不是诊断阈值。 [FEAT-008]
- 面积最大值（area_worst）：最大面积。在数据集中，良性组均值约 558.9，恶性组均值约 1422；良性组 5%~95% 区间 300.8 ~ 830.7，恶性组 734.4 ~ 2527。数值越高通常越提示细胞异型性明显（统计关联，非诊断阈值）。区间为该组 5%~95% 分位范围，属统计描述，不是诊断阈值。 [FEAT-024]

相似历史样本：最近的 5 个样本中，恶性 0 个、良性 5 个（相似度 0.917 ~ 1.000）。仅用于直观对照，属于数据集邻居，不构成临床证据。

下一步建议：结果提示良性可能性较高，建议按常规随访；若出现形态变化或新发症状，请及时就诊。

每句话，都有编号

答案正文用 [FEAT-008] 做行内标记；底部是可点击的依据芯片，点开即条款原文与来源级别。

INLINE
2
行内引用标记

CHIPS
5
可点击依据芯片

DROPPED
0
被丢弃的编造句

KNOWLEDGE BASE · 08

1,035 条条款，四个域

不是把网页一股脑塞进去：每条都有来源、级别、域标签。

487 NCI 治疗 MED-DISEASE	212 NCI 筛查 MED-DISEASE	141 NCI 预防 MED-DISEASE	61 维基百科 MED-DISEASE
34 MedlinePlus MED-DISEASE	30 特征词典 FEAT	28 系统文档 SYS	18 中国指南 2022 MED-DISEASE
10 NHS MED-DISEASE	7 策展 FAQ SYS	5 WHO MED-DISEASE	37 他莫昔芬 MED-DRUG

1,035

CLAUSES · 22 DOCS

四个域：疾病 933 / 药物 37 / 系统 35 / 特征 30

NCI · WHO · NHS · 指南 · 维基
FEATURES · SYS · FAQ

CORPUS GOVERNANCE · 09

先治理，再检索

BEFORE · 668 条

硬切 1100 字
到处都是"续 8"

398 条是碎片；发病率、参考文献、历史章节混在里面；引用点开经常没有上下文。

碎片率 60% · 噪声 14 条

AFTER · 1,035 条

按句切 260–900 字
每条独立可读

去统计/参考文献/历史；补副作用三源；文本哈希去重 23 条；全部打域与来源级别。

碎片 0 · 域 4 · 级别 4

HYBRID RETRIEVAL · 10

词法保准确，向量保召回

01
查询
原句 + 同义词扩展；解读类用特征名。

02
词法 Top30
中文单字 + 二元词，TF-IDF 倒排。

03
向量 Top30
bge-small-zh，512 维，余弦。

04
RRF 融合
倒数排名融合，不依赖分数尺度。

05
LLM 重排
Top20 交给模型按相关性排序。

06
域过滤
医学/系统分流，分数门槛后取 Top3。

141,762
倒排词条

1,035
向量条数

0.9s
热查询端到端（冷启动约 9s）

RETRIEVAL SPEC · 11

检索不是玄学，是一组参数

EMBEDDING

512 dim

bge-small-zh-v1.5 · ONNX CPU

CANDIDATES

30→20→3

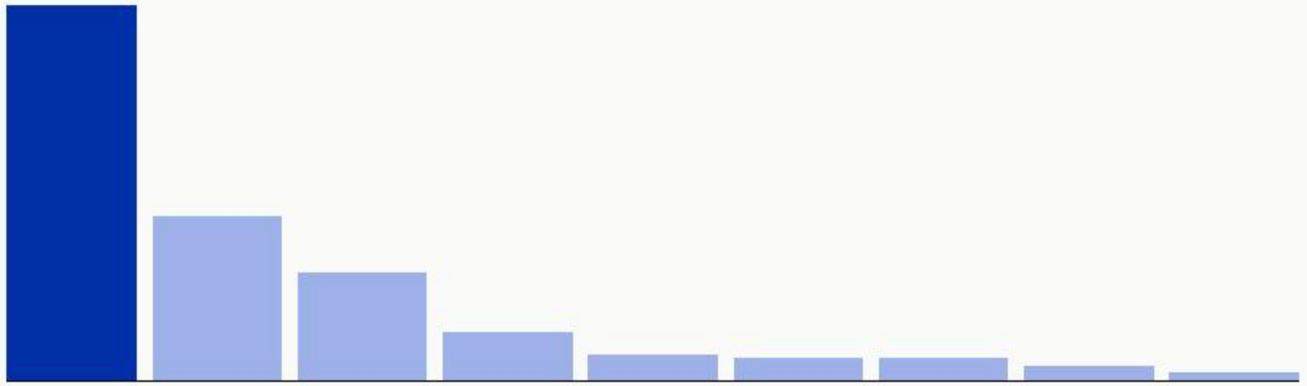
召回 / 融合 / 重排后输出

COLD START

9s

首次加载模型；之后 0.9s

右侧竖条是各来源的条款量（NCI 治疗 487 最高）。语料集中度决定了检索的主要证据来自 NCI 与指南。



SOURCE DISTRIBUTION · 487 / 212 / 141 / 61 / 34 / 30 / 28 / 18 / 10

RETRIEVAL RULES · 12

四条规则，把"乱引用"堵住

01 / ROUTING

按域检索

医学问题只搜 MED，系统问题只搜 SYS，解读搜 FEAT + MED；不让三类文档互相抢排名。

02 / GATE

引用门槛

只引用重排后 Top3 且分数 ≥ 8 的条款；没有合格依据就说没有，不硬挂维基。

03 / RERANK

模型重排

LLM 对 Top20 做 listwise 排序；失败自动退回 RRF 顺序，不阻断回答。

04 / FALLBACK

三级降级

向量不可用→只走词法；重排失败→保留融合序；全挂→旧单路检索。

涵盖便秘、腹泻、水肿、脱发、感染与中性粒细胞减少、血细胞降低及副作用管理等化疗相关问题。 (Mayo Foundation for Medical Education and Research) Also in Spanish Constipation and Cancer Treatment (National Cancer Institute) Also in Spanish Diarrhea and Cancer Treatment (National Cancer Institute) Also in Spanish Edema (Swelling) and Cancer Treatment (National Cancer Institute) Also in...

WEB-MLP-CHEMO-007 **儿童**

面向儿童及家长介绍化疗、中心静脉导管、输液港、PICC置管及化疗放疗副作用。 Central Lines (Central Venous Catheters) (Nemours Foundation) Also in Spanish Chemotherapy (Nemours Foundation) Also in Spanish Implanted Ports (Nemours Foundation) Also in Spanish Peripherally Inserted Central Catheter (PICC Line) (Nemours Foundation) Also in Spanish Side Effects of Chemotherapy and Radiation (For...

WEB-NCI-PREV-087 **芳香化酶抑制剂或灭活剂**

阿那曲唑、来曲唑抑制芳香化酶，依西美坦使其灭活，可预防激素敏感性乳腺癌，但有关节痛等副作用。 Another class of agents used to treat women with hormone-sensitive breast cancer may also prevent breast cancer.These drugs interfere with aromatase, the adrenal enzyme that allows estrogen production in postmenopausal women.Anastrozole and letrozole inhibit aromatase activity, whereas exemestane...

WEB-NCI-SCREEN-162 **经济负担与机会成本**

关注假阳性筛查结果带来的心理副作用及对后续筛查依从性的影响。 [PUBMED Abstract] Sandin B, Chorot P, Valiente RM, et al.: Adverse psychological effects in women attending a second-stage breast cancer screening.J Psychosom Res 52 (5): 303-9, 2002.[PUBMED Abstract] Brodersen J, Siersma VD: Long-term psychosocial consequences of false-positive screening mammography.Ann Fam Med 11 (2): 106-15,...

WEB-NCI-SIDE-001 **癌症治疗的副作用**

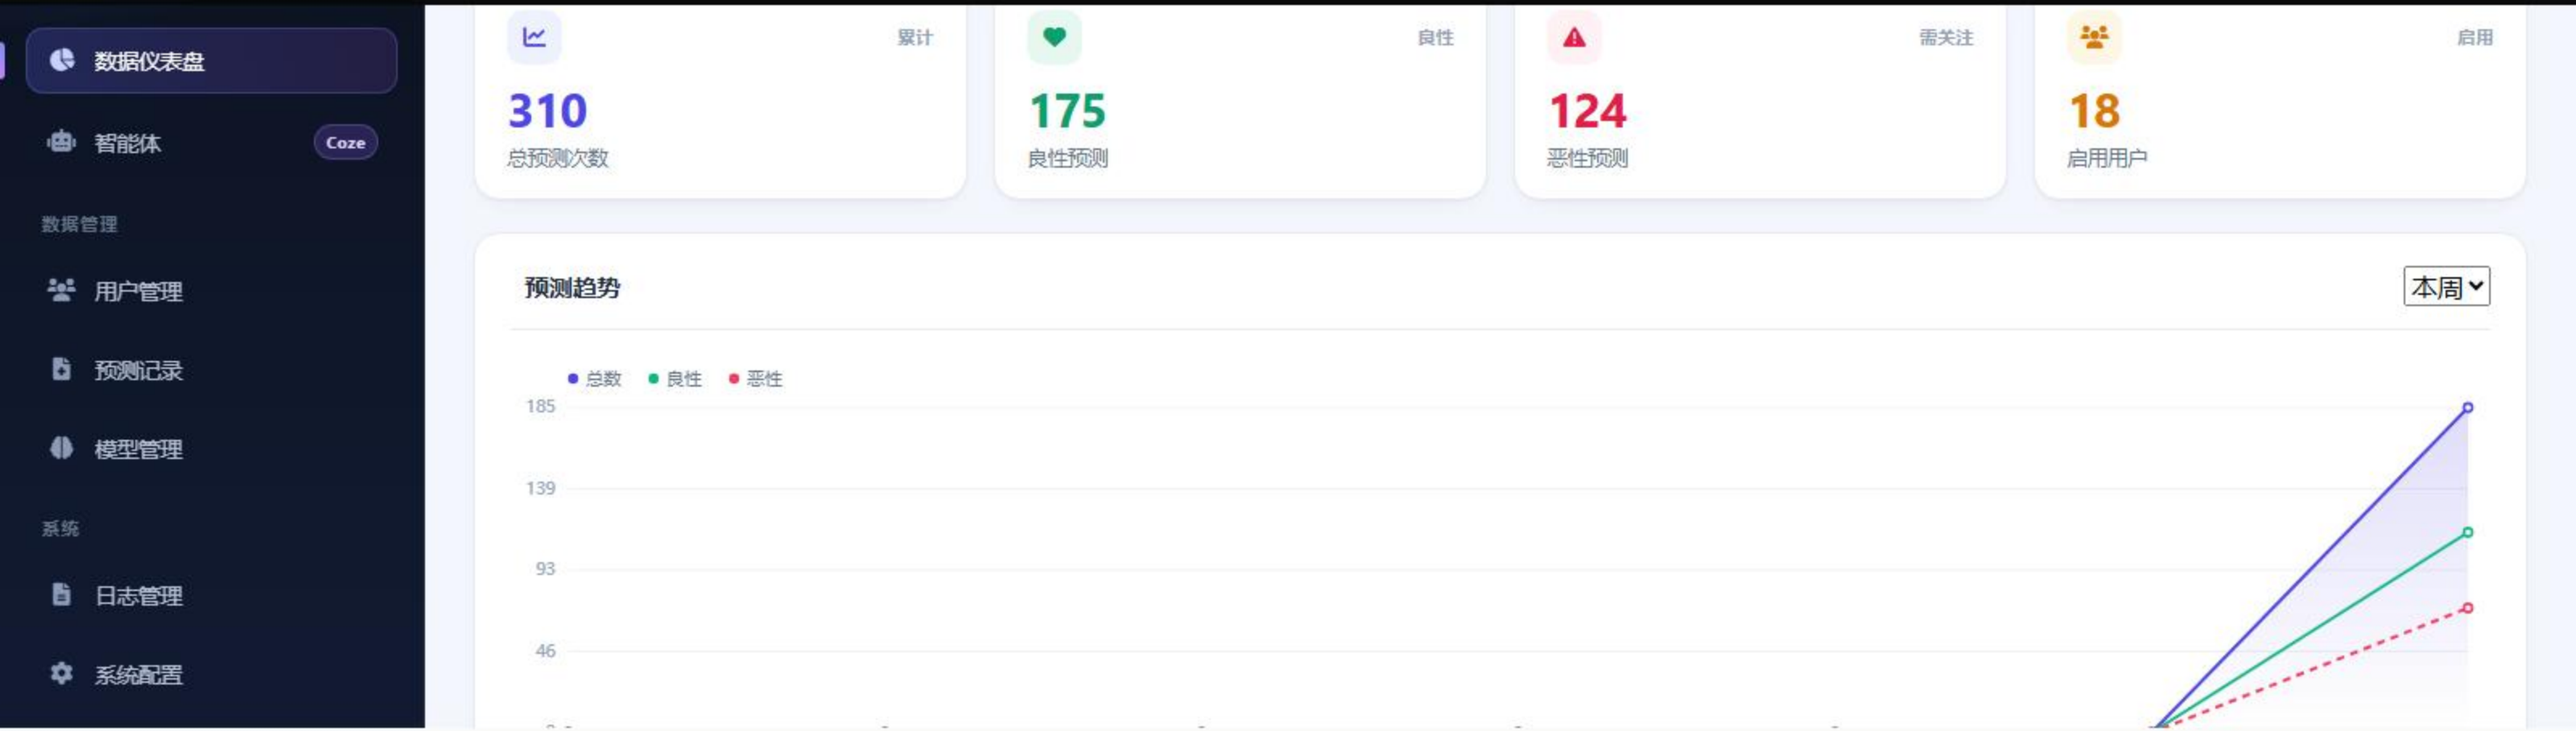
知识库，可以翻

按域筛选、关键词过滤、混合检索；每条显示来源、级别与原文链接，点开即可核对。

DOMAINS
4
疾病 / 药物 / 系统 / 特征

PAGE SIZE
18KB
服务端分页，每页 40 条

SOURCES
22
来源文档，带许可与链接



运营侧，另一个系统

管理端独立 Flask 服务，JWT + bcrypt + 权限表；看板、用户、记录、模型、日志、Coze 六个模块。

PREDICTIONS
310
累计预测

USERS
18
启用用户

F1
91.8%
模型性能面板

COZE INTEGRATION

令牌不出服务端 上下文自己拼

浏览器只访问本机 Flask；Flask 代理 Coze API，把数据库快照拼进 prompt，再以 SSE 回传。

PAT 只存环境变量 · 前端零接触



每次提问前：Flask 从 SQLite 取运营快照（用户 / 预测 / AI 会话）→ 拼进 prompt → 调 Coze → SSE 回传。



问运营，不用写 SQL

左侧是后台实时数据快照，右侧是 SSE 流式对话；Coze 连接状态、Bot ID、会话 ID 全部可见。

TODAY
185
今日预测

ACTIVE
6 / 6
今日活跃

AI CHAT
26 / 86
今日 / 累计会话

DELIVERY · 13

能跑、能测、能回滚

2	双服务 用户端 5000 · 管理端 5001 · Nginx 统一入口	SYSTEMD
1,035	向量索引 随包发布 4MB SQLite，部署不再现场建向量	SQLITE
73	单元测试 图节点、工具、grounding、RAG、会话全链路	PYTEST
20/20	评测用例 意图、引用、拒答、升级、对账、p95 延迟	EVAL
63/63	线上冒烟 页面、API、Agent、知识库、导出逐项检查	SMOKE

TAKEAWAYS

薄编排，厚证据。

编排层保持确定性，把不确定性关进工具与引用里。

张城杰 · 2026.10.18

01 **过程可见**
11 个节点、13 个工具、SSE 流式，模型不能黑箱作业。

02 **结论可查**
句子级 grounding + 1,035 条带来源的条款。

03 **边界清晰**
该弃权就弃权；Coze 只做运营，不碰诊断。

谢谢 · Q & A