GRADUATION DEFENSE · 2026.10.18

从概率到*依据*

乳腺癌辅助诊断系统的 Agent 编排、混合检索知识库，以及管理端 Coze 智能体。

答辩人 · 张城杰 · 计算机科学与技术

36 PAGES
≈ 30 MIN

← → 翻页 · B 动态 · ESC 总览 · P 演讲模式

THE PROBLEM

一个概率，回答不了三个人的问题。

医生 / 0.79 阈值

99.61% 是怎么校准的？依据在 FEAT-024 还是 NCI 条款？

患者 / 下一步

复查还是活检？报告能不能带走、能不能核对？

运营 / 310 次预测

今天多少人用、恶性占比多少、AI 会话增长如何？

SYSTEM OVERVIEW

三层结构，两条独立进程

用户端管诊断与解释，管理端管运营；共享知识库，不共享会话。

用户端是 Flask 应用，管理端是独立服务；两套进程共享同一份 SQLite 知识库，但权限和会话完全隔离。

L1 交互层
Flask + Jinja2 + 原生 JS；SSE 推流

L2 编排层
Graph 状态机；13 个工具；权限/超时

L3 证据层
集成模型 + 校准；RAG；SQLite

L1 · 交互层

`Flask 页面` `JSON API` `SSE` `Jinja2`

/predict · /result · /knowledge · /api/agent/llm/stream

L2 · 编排层

`Graph 10 节点` `13 工具` `权限` `checkpoint`

节点固定、边固定；每一步写检查点，可从任意节点续跑。

L3 · 证据层

`Voting / Stacking` `sigmoid 校准` `混合检索` `SQLite 18 表`

30 维特征 → 校准概率；1,035 条条款 → 词法 + 向量。

STACK · 01

没有前端框架，也没有向量数据库

每一层都能在答辩现场打开代码指给人看。

01
Python 3.11
Flask + gunicorn，17,350 行

02
Jinja2
21 个模板，服务端渲染

03
原生 JS
SSE 逐字渲染，无构建链

04
scikit-learn
Voting/Stacking + 概率校准

05
SQLite
18 张表：记录/检查点/RAG

06
TF-IDF
141,762 条倒排词条

07
bge-small-zh
512 维 ONNX，CPU 推理

08
Nginx + systemd
双服务 + GitHub Actions

17,350

LINES OF PYTHON · 173 FILES
另有 13,612 行模板、1,096 行 CSS、388 行 JS

0 前端框架
2 个 FLASK 进程

PREDICTION PIPELINE

一次预测，六步落地

01 细胞核形态

02 范围与单位校验

03 训练集均值方差

04 集成模型
Voting / Stacking

05 sigmoid + 温度缩放

06 入库 + 归因 + 证据

WDBC
569
良性 357 / 恶性 212

FEATURES
30
半径/纹理/面积/凹点

INFERENCE
0.022s
单次推理（结果页实测）

CALIBRATED
99.61%%
示例样本校准后置信度



结果页：先给证据，再给建议

恶性概率、校准置信度、输入距离、Top 5 归因、相似病例同屏；每个数字都能点开看来源。

CALIBRATED
99.61%
校准后置信度

DISTANCE
1.948
输入分布距离（上限 15）

LATENCY
0.022s
单次推理

01

PART 01 · AGENT 编排

AGENT 编排

01 Graph 状态机与检查点

02 工具契约与权限边界

03 同步 / 流式 / 子代理

04 三档不确定性与 grounding

10 个节点、13 个工具、13 类意图；流程固定，推理自由。

AGENT, NOT CHATBOT

会调工具，也会拒答。

INTENTS
13
含拒答与澄清

NODES
10
固定拓扑

TOOLS
13
统一权限/超时

TIERS
3
置信 / 谨慎 / 弃权

GRAPH · 10 NODES

节点固定，边固定，只有节点内部自由

guard 与 cache 都有条件边；其余是确定性流程。

01 **guard**
越界、敏感词、提示注入；命中直接进 refuse。

02 **cache**
同问同答；命中跳过 route，直接 persist。

03 **route**
13 类意图；导出动作优先于"能力询问"。

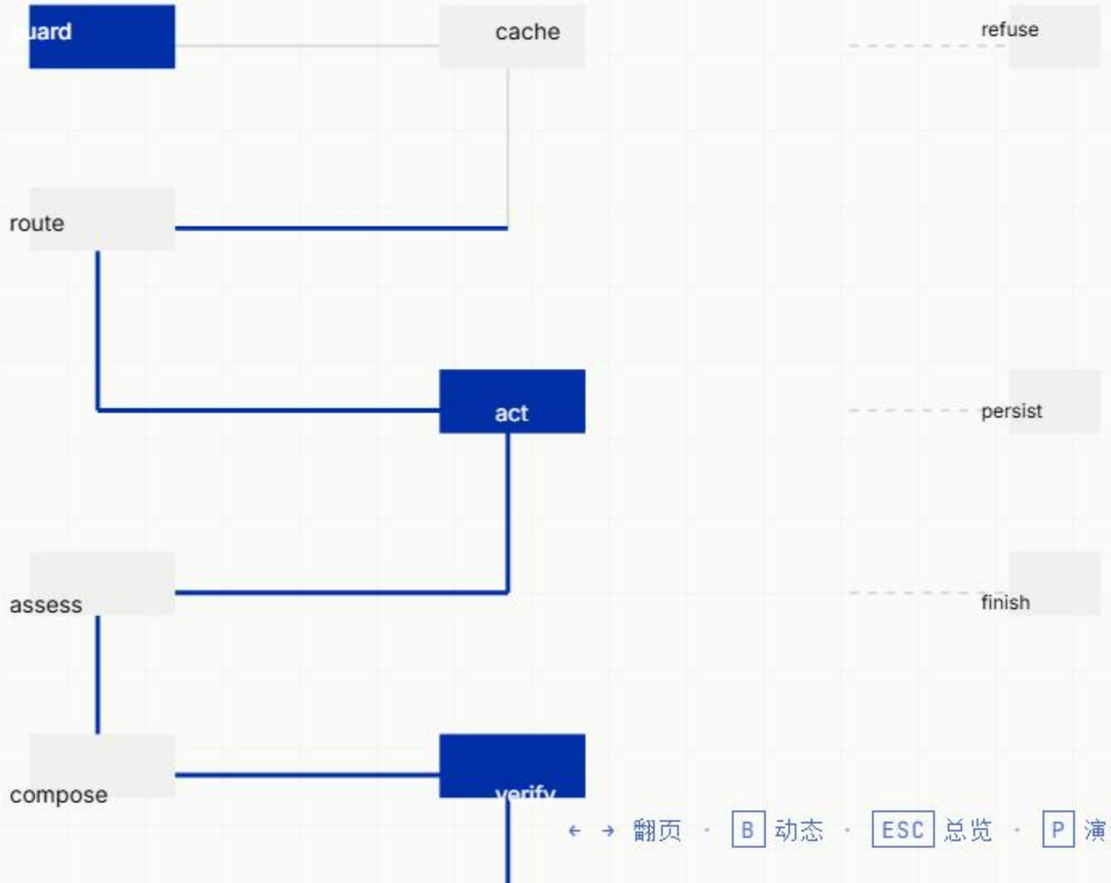
04 **act**
按意图调 1–5 个工具，写 facts 与 citations。

05 **assess**
置信度 + 输入距离 → 三档；可挂起等确认。

06 **compose**
按意图合成；医学答案只取重排前 3。

07 **verify**
数字对账 + 句子级 grounding；丢弃编造句。

08 **guard_out → persist**
免责声明、会话、引用、检查点。



STATE & CHECKPOINT

每一步都能回放，不靠日志猜

状态只存纯字典；检查点是可恢复的事实来源。

```
state = {
  'run_id': 'a1c9…',
  'question': '乳腺癌早期症状有哪些',
  'values': None,
  'intent': 'medical_qa',
  'facts': [ clause, … ],
  'citations': [ 'WEB-WHO-002', … ],
  'tier': 'confident',
  'verify': { ok: True, dropped: 0 },
  'status': 'ok'
}
```

状态是可序列化的纯字典；检查点写进 graph_checkpoints，按 run_id + seq 恢复。

A 每步保存
node、next、state、pending；出错也能定位到具体节点。

B 断点续跑
Interrupt 挂起后，从 resume_at 继续，不重复调模型。

C 可回放
同一 run_id 能重放节点顺序与耗时，用于排查和评测。

D 不存不可序列化对象
_emit、连接、模型句柄全部剔除，避免检查点写失败。

EXECUTION TRACE

一次解读请求的真实耗时

慢在哪一步，表里能直接看到。

#	节点	耗时	产物	说明
1	guard	0ms	—	无越界
2	cache	0ms	miss	首次提问
3	route	0ms	result_interpretation	含特征值
4	act	139ms	prediction + shap + FEAT 条款	模型 + 检索
5	assess	2ms	confident	置信 0.9961
6	compose	0ms	answer	模板合成
7	verify	0ms	ok	2 个数字对账
8	guard_out	0ms	—	免责声明
9	persist	3ms	run + citations	写库
10	finish	0ms	done	返回

同一问题首次调用 30.7s：冷启动要加载 90MB ONNX 模型并做 LLM 重排；热查询 139ms。

TOOL REGISTRY · 13 TOOLS

模型只能通过工具碰数据

13 个工具、8 种权限、5 档超时；没有一个直接读文件。

工具	权限	超时	幂等	作用
predict	predict	10s	是	30 维 → 概率
explain	explain	20s	是	近似 SHAP
search_knowledge	knowledge:read	25s	是	混合检索
get_clause	knowledge:read	5s	是	按 ID 取条款
records	records:read	10s	是	历史记录
statistics	stats:read	10s	是	个人统计
similar_cases	cases:read	5s	是	相似病例

工具	权限	超时	幂等	作用
compare_records	records:read	10s	是	两次对比
sql_query	stats:read	10s	是	只读聚合
export_report	report:generate	25s	否	PDF 报告
export_data	export	20s	否	CSV 导出
delegate	agent:delegate	90s	否	子代理
sessions	records:read	10s	是	会话列表

工具只能通过 registry.call_tool() 调用：参数先校验、权限先判定、超时与异常有确定语义。导出类标记非幂等，避免缓存误命中。

INTENT ROUTING

13 类意图，规则有先后

分类不是模型拍脑袋，是可测试的规则表。

意图	示例	判定依据
result_interpretation	这个结果什么意思?	有特征值 + 解读措辞
feature_question	面积平均值是什么意思	命中 30 个特征名
medical_qa	乳腺癌早期症状有哪些	医学关键词
usage	怎么导出报告	操作词 + 系统词
history	我一共做过多少次预测	统计/记录
similar_cases	找几个相似病例	相似/对照
report_export	生成一份完整报告	动作：生成
data_query	恶性占比多少	聚合/占比
record_compare	和上次比怎么样	两次记录
multi_step_task	逐条解释这些特征	多步/逐条
clarify	这个呢?	指代不清
refused	帮我确诊一下	越界：诊断/处方

ORDER MATTERS

规则有先后

导出动作先于"能力询问"；医学关键词先于通用解读；特征名先于医学词。

BUG FIXED

"用"不是操作词

曾把"副作用"里的"用"当成操作意图，导致医学问题走成 usage；已改为"怎么用/如何使用"。

FALLBACK

拿不准就问

指代不清进 clarify；越界进 refused；不硬猜。

TWO ENGINES

同一张图，两种交付

同步给机器，流式给人。

SYNC · /API/AGENT/RUN-SYNC

一次返回
适合评测

完整 JSON：intent、answer、citations、verify、graph trace。评测脚本与自动化用它，字段可断言。

A **字段稳定**
intent / citations / verify / graph 都可断言。

```
POST /api/agent/run-sync
{ "question": "…" }
→ { intent, answer_md,
    citations, verify,
    graph: [10 steps] }
```

STREAM · /API/AGENT/LLM/STREAM

边想边给
过程可见

SSE 事件：start / thinking / token / tool_call / tool_result / sub_steps / done；失败发 fallback，前端重试两次。

A **7 类事件**
start / thinking / token / tool_call / tool_result / sub_steps / done。

```
event: start
data: {"question":"…"}
event: thinking
data: {"step":1}
event: token
data: {"delta":"乳腺癌"}
```

SUBAGENT

长任务拆出去，权限收回来

子代理是执行体，不是第二个大脑。

主代理负责一次问答；遇到"逐条解释 30 个特征"这类长任务，拆给子代理，避免主循环被单次工具调用拖死。

01 **只读**
子代理工具集不含 export / predict，避免副作用。

02 **禁止递归**
子代理不能再 delegate，深度固定为 1。

03 **超时 90s**
超时返回结构化错误，主代理降级为逐项处理。

CONTRACT

delegate(question, scope)

返回 summary + facts + citations；主代理只信结构化结果，不解析自然语言。

WHY NOT LOOP

主循环有上限

Graph 最多 40 步；子任务放子代理里跑，主图不会被撑爆。

TRACE

sub_steps 事件

子代理的步骤以 sub_steps 推给前端，过程仍然可见。

UNCERTAINTY · 3 TIERS

不知道的时候，敢说不知道

三档不是文案，是流程分支。

CONFIDENT

置信

校准置信度 ≥ 0.79，输入距离 ≤ 15；正常给结论与建议。

0.79

CLARIFY

谨慎

0.41–0.79：给倾向，标注不确定，建议补充分期/分型。

0.41

ABSTAIN

弃权

低于 0.41 或距离 > 15：直接说"超出可靠范围"，不给结论。

15.0

阈值不是拍脑袋：0.79 / 0.41 来自校准曲线与误判成本；15 是训练分布距离的经验上限。评测里三档都有对应用例。

误判成本：假阴性 > 假阳性
所以弃权比硬答更安全

GROUNDING

每句话，都要对得上事实

引用不是脚注，是逐句核对后的结果。

01 **句子切分**
中文按 。！？；，英文按句号；每句独立核对。

02 **数字对账**
容差 max(0.02, |数值| × 0.002)；对不上就标记。

03 **断言绑定**
每句映射到 clause_id 或 prediction/shap 事实；无出处标"推断"。

04 **无据丢弃**
编造数字整句删除，verify 记录 dropped；答案里不再出现。

```
def ground(answer, facts, citations):
    for sent in split_sentences(answer):
        nums = extract_numbers(sent)
        bad = [n for n in nums
               if not in_fact_pool(n, facts)]
        if bad:
            drop(sent)  # 整句丢弃
    return { ok, coverage,
             claims, dropped }
```

覆盖率与丢弃数随答案返回；前端可展示"这句话没有依据"。

主要归因（数值来自模型归因结果，不是推测）：

1. `concave points_mean` = 0.0139 —— 推向良性
2. `concave_worst` = 0.0691 —— 推向良性
3. `area_worst` = 546.3 —— 推向良性
4. `perimeter_worst` = 85.22 —— 推向良性
5. `concavity_mean` = 0.0267 —— 推向良性

指标含义（引用特征词典）：

- 凹点平均值（concave points_mean）：轮廓凹陷点的数量。在数据集中，良性组均值约 0.0257，恶性组均值约 0.088；良性组 5%~95% 区间 0.0032 ~ 0.0564，恶性组 0.0339 ~ 0.1511。数值越高通常越提示细胞异型性明显（统计关联，非诊断阈值）。区间为该组 5%~95% 分位范围，属统计描述，不是诊断阈值。 [FEAT-008]
- 面积最大值（area_worst）：最大面积。在数据集中，良性组均值约 558.9，恶性组均值约 1422；良性组 5%~95% 区间 300.8 ~ 830.7，恶性组 734.4 ~ 2527。数值越高通常越提示细胞异型性明显（统计关联，非诊断阈值）。区间为该组 5%~95% 分位范围，属统计描述，不是诊断阈值。 [FEAT-024]

相似历史样本：最近的 5 个样本中，恶性 0 个、良性 5 个（相似度 0.917 ~ 1.000）。仅用于直观对照，属于数据集邻居，不构成临床证据。

下一步建议：结果提示良性可能性较高，建议按常规随访；若出现形态变化或新发症状，请及时就诊。

每句话，都能点开

正文用 [FEAT-008] 做行内标记；底部是可点击的依据芯片，点开即条款原文与来源级别。

INLINE
2
行内引用标记

CHIPS
5
可点击依据芯片

DROPPED
0
被丢弃的编造句

02

PART 02 · 知识库

知识库

01 语料构成与治理

02 索引结构与混合检索

03 域路由与引用门槛

04 检索效果与失败案例

1,035 条条款、22 个来源；先治理，再检索，再重排。

CORPUS

语料不是越多越好，是要能对上问题

每个来源都有级别、域和原文链接。

487 NCI 治疗	212 NCI 筛查	141 NCI 预防	61 维基百科
34 MedlinePlus	37 他莫昔芬	30 特征词典	28 系统文档
18 中国指南	10 NHS	7 FAQ	5 WHO

1,035

CLAUSES · 22 DOCS · 4 DOMAINS

疾病 933 / 药物 37 / 系统 35 / 特征 30

CORPUS GOVERNANCE

先治理，再检索

切块方式决定了引用能不能读。

BEFORE · 668 条

硬切 1100 字
到处都是"续 8"

398 条碎片；发病率、参考文献、历史章节混入；引用点开没有上下文。

碎片率 60% · 噪声 14 条 · → 引用不可读

AFTER · 1,035 条

按句切 260–900 字
每条独立可读

去统计/参考文献/历史；补副作用三源 18 条；文本哈希去重 23 条；全部打域与来源级别。

碎片 0 · 域 4 · 级别 4

INDEX

四张表，一个文件

倒排、向量、正文、FTS 都在 SQLite 里。

表	内容	规模
rag_chunks	条款正文 + 域/级别/URL	1,035
rag_terms	倒排：词 → clause_id	141,762
rag_vectors	512 维 float32 BLOB	1,035
rag_fts*	SQLite FTS5 辅助索引	—

没有外部向量库：1,035 条向量在内存里做余弦，单次 <5ms。

```
# 重建索引（部署时执行）
python -m agent.rag.build

# 只重建向量
RAG_BUILD_VECTORS=1 \
  python -m agent.rag.build

# 向量随包发布，避免服务器 OOM
agent/knowledge/rag_vectors.sqlite
```

部署机上向量构建曾因 90MB ONNX 模型 OOM（exit 137），改为本地预计算 + 4MB SQLite 随包发布。

HYBRID RETRIEVAL

词法保准确，向量保召回

两路召回、一次融合、一次重排。

01
查询
原句 + 同义词；解读类用特征名，医学类保留原句。

02
词法 Top30
中文单字 + 二元词，TF-IDF；专有名词与编号更稳。

03
向量 Top30
bge-small-zh，512 维；换说法也能召回。

04
RRF 融合
score = Σ 1/(60+rank)；不依赖两路分数尺度。

05
LLM 重排
Top20 交给模型 listwise 排序；失败退回 RRF。

06
域过滤
医学/系统分流，分数 ≥8 才进引用，取 Top3。

```
lex = index.search(q, k=30, D)
vec = embed.search(q, k=30)
fused = rrf(lex, vec)[:20]
ranked = llm_rerank(q, fused, top=3)
return [c for c in ranked if c.score > 8]
```

FALLBACK

向量不可用 → 只走词法；重排超时 → 保留 RRF 顺序；都失败 → 旧单路检索。

NO SINGLE POINT OF FAILURE

CITATION RULES

四条规则，把"乱引用"堵住

引用质量靠规则，不靠 prompt 祈祷。

01 / ROUTING

按域检索

医学问题只搜 MED-DISEASE / MED-DRUG；系统问题只搜 SYS；解读搜 FEAT + MED。三类文档不互相抢排名。

02 / GATE

引用门槛

只引用重排后 Top3 且分数 ≥ 8 的条款；没有合格依据就说没有，不硬挂维基。

03 / RERANK

模型重排

LLM 按"是否真的回答问题"排序；超时 25s，失败保留 RRF 顺序。

04 / FALLBACK

三级降级

向量不可用 → 词法；重排失败 → RRF；全挂 → 旧单路。每一级都有测试覆盖。

RETRIEVAL QUALITY

同一个问题，引用换了三条

不回避旧版本的错误，直接对比。

问题	旧结果（668 条语料）	新结果（1,035 条 + 混合检索）
化疗副作用怎么缓解	WHO 处理 / 他莫昔芬 / 芳香化酶抑制剂	NCI 副作用管理 / NCI 副作用 / NHS 化疗副作用
乳腺癌早期症状	WHO 处理 / WHO 症状 / 维基症状	MedlinePlus 症状 / WHO 症状 / WHO 处理
怎么导出报告	DOC-AGENT-001「助手能做什么」	FAQ-RECORDS「记录在哪、怎么删、怎么导出」

01 / CHUNKING

切块方式

1100 字硬切 → 句子边界 260–900 字；398 条"续 N"碎片清零。

02 / DOMAIN

域路由

系统文档不再和医学条款抢排名；医学问题只搜 MED。

03 / FAQ

操作问题走策展

"怎么导出"直接命中 FAQ-RECORDS，不落到"助手能做什么"。

WARM
0.9s
热查询端到端

COLD
9s
首次加载模型

VECTORS
1,035
全部在 SQLite

涵盖便秘、腹泻、水肿、脱发、感染与中性粒细胞减少、血细胞降低及副作用管理等化疗相关问题。 (Mayo Foundation for Medical Education and Research) Also in Spanish Constipation and Cancer Treatment (National Cancer Institute) Also in Spanish Diarrhea and Cancer Treatment (National Cancer Institute) Also in Spanish Edema (Swelling) and Cancer Treatment (National Cancer Institute) Also in...

WEB-MLP-CHEMO-007 **儿童**

面向儿童及家长介绍化疗、中心静脉导管、输液港、PICC置管及化疗放疗副作用。 Central Lines (Central Venous Catheters) (Nemours Foundation) Also in Spanish Chemotherapy (Nemours Foundation) Also in Spanish Implanted Ports (Nemours Foundation) Also in Spanish Peripherally Inserted Central Catheter (PICC Line) (Nemours Foundation) Also in Spanish Side Effects of Chemotherapy and Radiation (For...

WEB-NCI-PREV-087 **芳香化酶抑制剂或灭活剂**

阿那曲唑、来曲唑抑制芳香化酶，依西美坦使其灭活，可预防激素敏感性乳腺癌，但有关节痛等副作用。 Another class of agents used to treat women with hormone-sensitive breast cancer may also prevent breast cancer.These drugs interfere with aromatase, the adrenal enzyme that allows estrogen production in postmenopausal women.Anastrozole and letrozole inhibit aromatase activity, whereas exemestane...

WEB-NCI-SCREEN-162 **经济负担与机会成本**

关注假阳性筛查结果带来的心理副作用及对后续筛查依从性的影响。 [PUBMED Abstract] Sandin B, Chorot P, Valiente RM, et al.: Adverse psychological effects in women attending a second-stage breast cancer screening.J Psychosom Res 52 (5): 303-9, 2002.[PUBMED Abstract] Brodersen J, Siersma VD: Long-term psychosocial consequences of false-positive screening mammography.Ann Fam Med 11 (2): 106-15,...

WEB-NCI-SIDE-001 **癌症治疗的副作用**

知识库：可以翻，也可以搜

按域筛选、关键词过滤、混合检索；每条显示来源、级别与原文链接，点开即可核对。

DOMAINS
4
疾病 / 药物 / 系统 / 特征

PAGE
18KB
服务端分页，每页 40 条

SOURCES
22
带许可与原文链接

03

PART 03 · 运营与交付

运营与交付

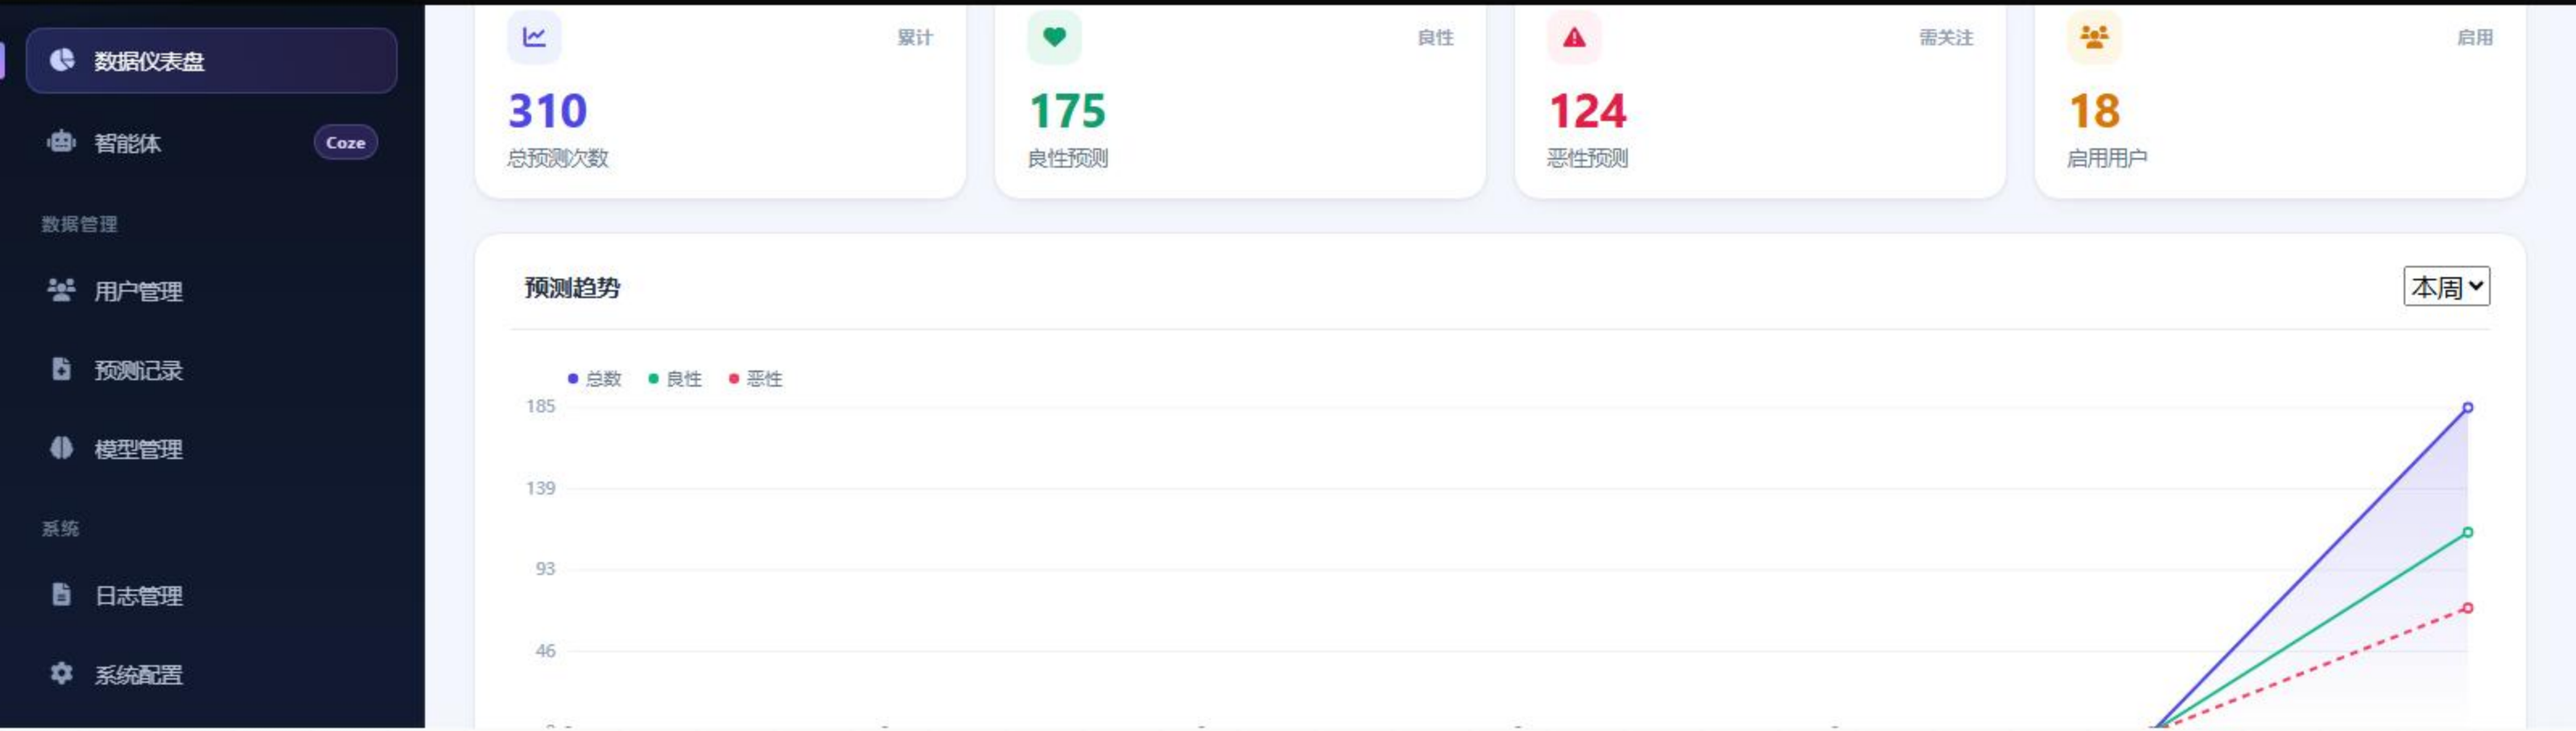
01 管理端独立服务

02 Coze 服务端代理

03 测试 / 评测 / 冒烟

04 取舍与局限

管理端 COZE 智能体、工程质量，以及这套系统的边界。



管理端：另一个进程，另一套权限

独立 Flask 服务，JWT + bcrypt + 权限表；看板、用户、记录、模型、日志、Coze 六个模块。

PREDICTIONS
310
累计预测

USERS
18
启用用户

F1
91.8%
模型性能面板

COZE INTEGRATION

令牌不出服务端，上下文自己拼

Coze 是运营助手，不是第二个诊断模型。

浏览器只访问本机 Flask；Flask 代理 Coze API，把数据库快照拼进 prompt，再以 SSE 回传。PAT 只存在服务器环境变量。

01 **代理而非直连**
前端拿不到 PAT，也拿不到 Coze 原始响应头。

02 **上下文自拼**
用户、预测、模型、AI 会话四个维度；最近 6 条记录。

03 **失败降级**
Coze 超时返回明确错误，管理端其他模块不受影响。



提问前：快照（用户 / 预测 / 模型 / AI 会话）→ 拼 prompt → Coze → SSE 回传。



问运营，不用写 SQL

左侧是后台实时数据快照，右侧是 SSE 流式对话；Coze 连接状态、Bot ID、会话 ID 全部可见。

TODAY
185
今日预测

ACTIVE
6 / 6
今日活跃

AI CHAT
26 / 86
今日 / 累计会话

COZE BOUNDARY

能做什么，不能做什么

避免把运营助手误当成医疗模型。

WHAT IT DOES

查运营
做汇总

今日预测、恶性占比、活跃用户、AI 会话趋势；把自然语言问题转成运营回答，并给出数据快照。

只读 · 有数据出处

WHAT IT DOESN'T

不做诊断
不开处方

Coze 不接患者数据、不读影像、不生成诊断结论；用户端的拒答规则不依赖 Coze。

边界写进 PROMPT 与页面

ENGINEERING

能跑、能测、能回滚

每个数字都能在仓库里找到对应脚本。

73	**单元测试** 图节点 / 工具 / grounding / RAG / 会话 / 批量	PYTEST
20/20	**评测用例** 意图、引用、拒答、升级、数字对账、p95 延迟	EVAL
63/63	**线上冒烟** 页面、API、Agent、知识库、导出逐项检查	SMOKE
60s	**部署耗时** GitHub Actions → 华为云；索引重建 + 重启 + 自检	CI/CD
4MB	**向量随包** 1,035 条向量 SQLite；不再现场构建，避免 OOM	ARTIFACT

EVALUATION

指标不是装饰，是门禁

不达标 CI 直接失败。

指标	结果	阈值	说明
意图准确率	1.000	≥ 0.90	20 条用例全部命中
引用率	1.000	≥ 0.90	需要引用的答案都有 citation
拒答准确率	1.000	= 1.00	诊断/处方/提示注入全部拒绝
升级准确率	1.000	= 1.00	高风险问题正确升级
对账通过率	1.000	= 1.00	答案数字全部能在 facts 找到
p95 延迟	221ms	≤ 8000ms	离线确定性路径

COVERED

确定性路径

意图、引用、拒答、升级、对账、离线 p95；都可复现。

NOT COVERED

自由生成上限

LLM 措辞质量、临床有效性、真实医生采纳率，都没有量化。

NEXT

检索评测集

30 道医学题测 recall@5 与 citation precision，再接临床前瞻。

评测不覆盖 LLM 自由生成的质量上限，只覆盖确定性路径与安全边界；这也是下一阶段要补的部分。

TRADEOFFS

四个选择，都有代价

答辩更愿意讲清楚放弃了什么。

01 / GRAPH

自研 163 行

不引 LangGraph：依赖少、节点可单测、状态可回放；代价是生态与现成能力要自己补。

02 / RETRIEVAL

词法 + 向量

比纯词法多 90MB 模型和 9s 冷启动；换来的换说法召回，在医学术语上值得。

03 / STORAGE

SQLite

没有向量库、没有 Redis；1,035 条规模下内存余弦足够，部署只需一个文件。

04 / CONCURRENCY

单 worker

gunicorn 1 worker × 4 threads，避免多进程重复加载模型；代价是并发上限。

LIMITATIONS

四个局限，和对应的下一步

不把"能跑"说成"能临床用"。

01 **词法仍有盲区**
"靠不靠谱"搜不到"置信度"；同义词表只有 10 组，覆盖有限。

02 **重排延迟 0.8–1.2s**
LLM listwise 比向量检索慢；离线评测不包含这部分。

03 **冷启动 9s**
首次加载 ONNX 模型；之后热查询 0.9s。生产可用预热解决。

04 **没有临床前瞻验证**
只有 WDBC 回溯数据；不能声称临床有效性。

NEXT · 01

查询改写

把"靠不靠谱"改写成"置信度 / 校准"，补词法盲区。

NEXT · 02

重排缓存

同 query 的重排结果缓存，降低重复延迟。

NEXT · 03

临床评估

与医院合作做前瞻性评估，才有资格谈临床价值。

TAKEAWAYS

薄编排，厚证据。

流程保持确定性，把不确定性关进工具、阈值和引用里。

张城杰 · 2026.10.18

01 **流程可复现**
10 个节点、13 个工具、检查点；每一步都能回放。

02 **结论可核对**
1,035 条带来源的条款 + 句子级 grounding。

03 **边界先讲清**
三档不确定性、拒答规则、Coze 只做运营。